Искамцев Ильдан. Efficient NN: HW1

Аналитическая модель CNN

$U = BS^2$, $32 \le S \le 512$, S кратно 16, $1 \le B \le 256$.

Вход: $B \times 3 \times S \times S$

Выход: $B \times 100$

FP32: 4 байта

eval + inference mode

ReLU inplace

Conv без bias

padding $k//2$

linear с bias

TF32 и cuDNN benchmark выключены.

Каналы Conv: 3, 32, 64, 128, 256, 256, 512

Ядра: 7, 5, 3, 1, 3, 1

stride: 2, 1, 2, 1, 2, 1

После Conv 1 + ReLU: MaxPool (3, 2, 1)

Размеры выходов Conv: $\frac{S}{2}$, $\frac{S}{4}$, $\frac{S}{8}$, $\frac{S}{8}$, $\frac{S}{16}$, $\frac{S}{16}$

Голова: GAP, FC $512 \to 256$, ReLU, FC $256 \to 100$.

1 MAC = 2 FLOPs; сравнения ReLU и MaxPool игнорируем.

Для Conv и FC:

$$W_c = C_{in} C_{out} k^2, \quad F_c = 2 B H_{out}^2 W_c$$

$$W_{Fc} = (C_{in} + 1) \cdot C_{out}, \quad F_{Fc} = B(2C_{in} + 1) \cdot C_{out}$$

Q считаем прочитанные и записанные байты. Одно чтение входа и весов, одна запись выхода; кэши, повторные загрузки и workspace не учитываем:

$$Q_{c/Fc} = 4 (N_{in} + N_{out} + W_c), \quad Q_{ReLU} = 8N$$

Операция	Параметры W_i	F_i	Q_i, байта
Conv 1	4704	2352 И	44 И + 4W_i
Conv 2	51200	6400 И	24 И + 4W_i
Conv 3	73728	2304 И	24 И + 4W_i
Conv 4	32768	1024 И	24 И + 4W_i
Conv 5	589824	4608 И	20 И + 4W_i
Conv 6	131072	1024 И	12 И + 4W_i
GAP	0	2 И	8 И + 2048 В
FC 1	131328	262400 В	3072 В + 4W_i
FC_2	25700	51300 В	1424 В + 4W_i
Bce 4 ReLU	0	0	168 И + 2048 В
MaxPool	0	0	56 И

Для GAP при $n = \left(\frac{S}{16}\right)^2$: $F = 512\,B\left((n-1)+1\right) = 2\,И$

MaxPool запоминаем int64-индексы: $Q = 4(8И + 2И) + 8 \cdot 2И = 56\,И$

Суммируем строки: $N_p = \sum W_i = 1040324$

$$F = (17412 + 2) \cdot И + (262400 + 51300) \cdot B = 17414\,BS^2 + 313700\,B$$

$$Q = 4N_p + (148 + 8 + 168 + 56) \cdot И + (4496 + 2048 + 2048) \cdot B = 4161296 + 380\,BS^2 + 8592\,B$$ байтов

Память

Веса: $4N_p$ байт. Вход сохраняется, временные активации освобождаются, ReLU in-place. На MaxPool одновременно живы исходный вход 3Ч, вход слоя 8Ч, выход 2Ч FP32-чисел и 2Ч int64-индексов:

$$M_{pool} = 4(3Ч+8Ч+2Ч)+8\cdot 2Ч = 68Ч.$$

Для остальных слоев активации занимают не более $\max(44Ч, 20Ч+2048В, 12Ч+3072В) \le 68Ч$. Поэтому

$$M(S,B) = 4N_p + 68Ч = 4161296 + 68BS^2 \text{ байт}.$$

Сравниваем с абсолютным max_memory_allocated() за один forward. Шейдеры cuDNN и округление аллокатора исключены, поэтому реальный пик может быть выше. Подгоночными нет.

Время

Измеряем медианой wall-clock время forward с синхронизацией CUDA. $P > 0$ в FLOPs/s, $W > 0$ в $\frac{\text{bytes}}{s}$, $t_0 \ge 0$ в секундах. Вычисления и обмен внутри операции перекрываются; операции выполняются последовательно:

$$T_i = \max\left(F_i/P, Q_i/W\right), \quad T(S,B,\theta_T) = t_0 + \sum_{i \in \text{таблица}} \max\left(F_i/P, Q_i/W\right),$$

$$\theta_T = (t_0, P, W)$$

Строка ReLU объединяет 4 операций с $F_i = 0$, поэтому их времена складываются точно. P, W эффективные и постоянные; смена алгоритмов и кэше не моделируются. Предполагаем t_0: launch-bound; для слоя $F_i/P > Q_i/W$: compute-bound, иначе memory-bound.

Энергия:

Энергия всей GPU на forward, включая простой:

$$E_{meas} = \frac{1}{n} \int_{window} P_{GPU}(t)\,dt$$ для n проходов. Предполагаем затраты, пропорциональные времени, FLOPs и трафику:

$$E(S, B, \theta_E) = P_0 T(S, B, \theta_T) + \varepsilon_F (17714\,BS^2 + 313400\,B) + \varepsilon_Q (4161296 + 380\,BS^2 + 8592\,B)$$

$P_0 \geq 0$ в W, $\varepsilon_F \geq 0$ в J/FLOPs, $\varepsilon_Q \geq 0$ в J/byte; результат в J.

Коэффициенты эффективные: P_0 не является измерением мощности простоя. Сначала подбираем θ_T, затем $\theta_E = (\theta_T, P_0, \varepsilon_F, \varepsilon_Q)$ только на успешных базовых точках. Проверочные точки в подборе не участвуют; в прогнозе энергии используем предсказанное T!